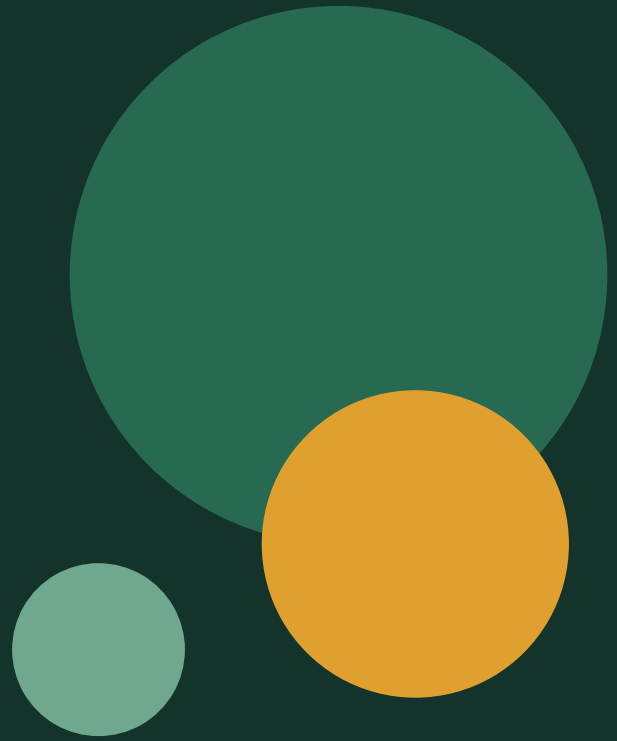
Data drifting: paso a paso

Todo lo trabajado y la mejor combinación de variables

Problema #02 · R + LightGBM · Grupo A

Noviembre 2026



La respuesta, en una página

0.9349

AUC medio de la combinación ganadora (10 semillas, validación 202107)

Desvío entre semillas: 0.0006

Corrección	rank_cero_fijo: el 0 queda en 0 y el resto se rankea por mes
Variables	Intra-mes + lag1, lag2 y deltas (272 campos), sin k-means
LightGBM	256 hojas · min_data_in_leaf 2048 · feature_fraction 0.8
Ensamble	01 + 05 llega a AUC 0.93624; un solo mes de validación

La pregunta y el diseño

¿Qué efecto tiene corregir el data drifting de las variables monetarias (IPC, tipo de cambio u otros métodos) sobre el desempeño del modelo, frente a no tratarlo?

Entrenamiento	Validación	Entrenamiento final	Futuro
201901–202105	**202107**	**201901–202107**	**202109**

10 semillas por configuración

9 configuraciones comparadas

50 combinaciones de hiperparámetros por configuración

El paso a paso

1 Datos

Competencia 2026; positivos = BAJA+1 y BAJA+2

2 Corregir el drift

rank_cero_fijo, deflación por IPC, dólar oficial o blue

3 Variables nuevas

Intra-mes y lag1, lag2 con deltas; k-means opcional

4 Grid Search

50 combinaciones de hiperparámetros; se elige por AUC

5 10 semillas

10 modelos de validación y 10 finales por configuración

6 Ensamble y cortes

Promedio de probabilidades; cortes 1600–2600 para Kaggle

Cómo evolucionó el trabajo

24/10	Cambio al Problema #02; notebook base en R + LightGBM
Baseline	Sin corregir, 1 semilla: 89.470 en el público (corte 2200)
31/10–1/11	10 semillas, probabilidades guardadas y notebook 06 (WF9600–9609)
7/11	NEW201: intra-mes vs k-means, 9 configuraciones × 10 semillas
8/11	Wilcoxon y ensambles; base = 01, sin envío a Kaggle
Próximo	NEW202: lags largos, medias móviles y grid ampliado (por correr)

Qué se combinó

Nº	Corrección del drift	Variables	Campos
01	**rank_cero_fijo**	**Intra-mes**	**272**
02	Deflación (IPC)	Intra-mes	272
03	Deflación ÷ dólar oficial	Intra-mes	272
04	Deflación ÷ dólar blue	Intra-mes	272
05	rank_cero_fijo	Intra-mes + k-means como variable	282
06	Deflación (IPC)	Intra-mes + k-means como variable	282
07	Deflación ÷ dólar oficial	Intra-mes + k-means como variable	282
08	Deflación ÷ dólar blue	Intra-mes + k-means como variable	282
09	rank_cero_fijo	Intra-mes + k-means como drift	272

Resaltada: la configuración ganadora. Cada una corre con 10 semillas y grid de 50 combinaciones.

Cuatro correcciones de drift

1 rank_cero_fijo

0.9349
config 01

El 0 queda en 0; positivos y negativos se rankean por separado en cada mes.

2 Deflación por IPC

0.9333
config 06

Los montos se multiplican por el IPC, con base 31-dic-2020.

3 Dólar blue

0.9330
config 04

Los montos se dividen por el tipo de cambio blue.

4 Dólar oficial

0.9326
config 07

Los montos se dividen por el tipo de cambio oficial.

Número a la derecha: mejor AUC medio de las configuraciones que usan esa corrección (10 semillas).

Variables: intra-mes y k-means

Intra-mes

kmes y mpayroll_sobre_edad (usa mpayroll_rank).

Está en las 9 configuraciones.

Histórico

lag1, lag2, delta1 y delta2 de las variables.

Con intra-mes suman 272 campos en total.

K-means (k = 8)

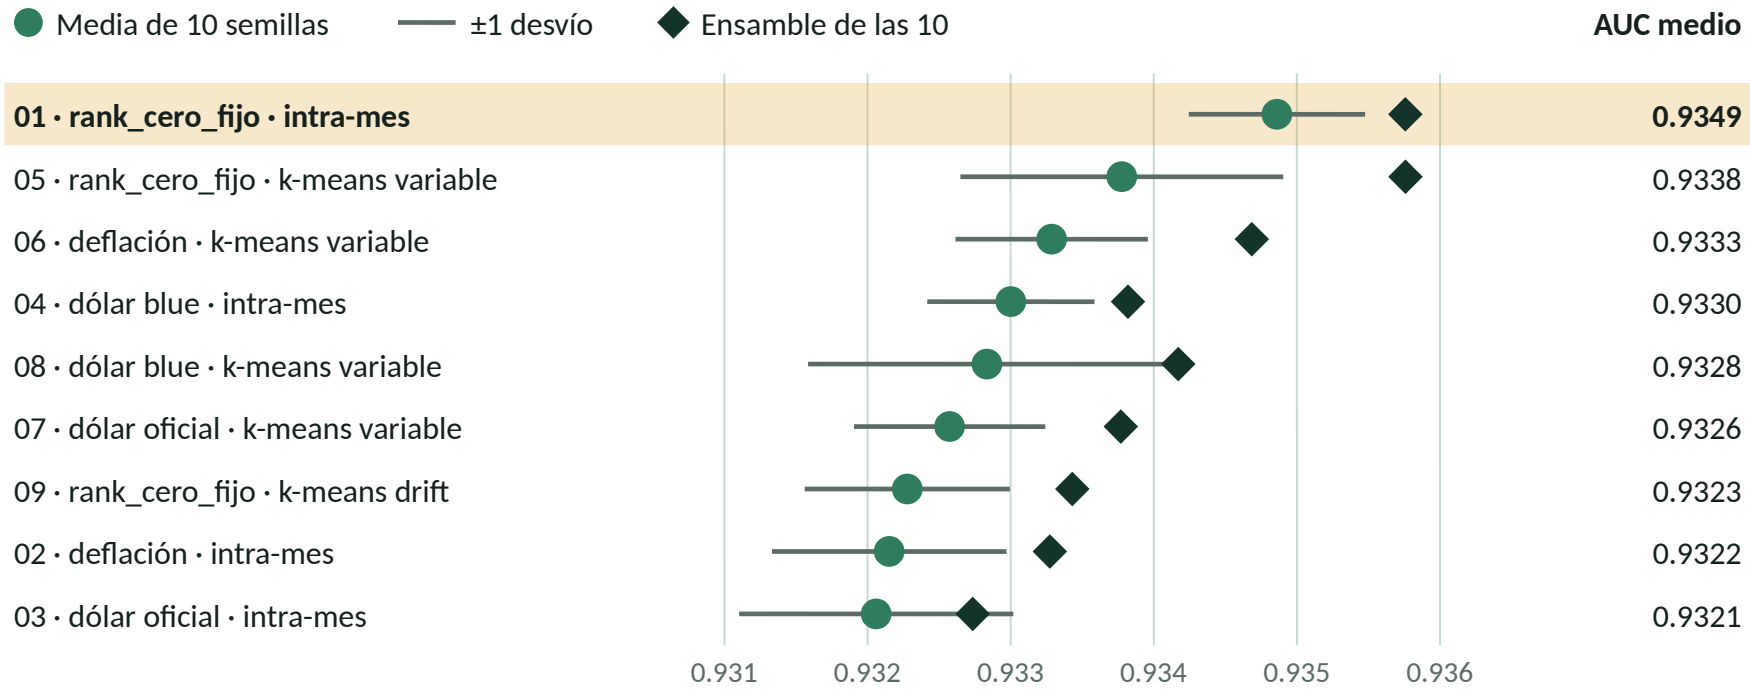
Se ajusta una vez sobre rank intra-mes de monetarias, edad y antigüedad.

Como variable: cluster + distancias, 282 campos.

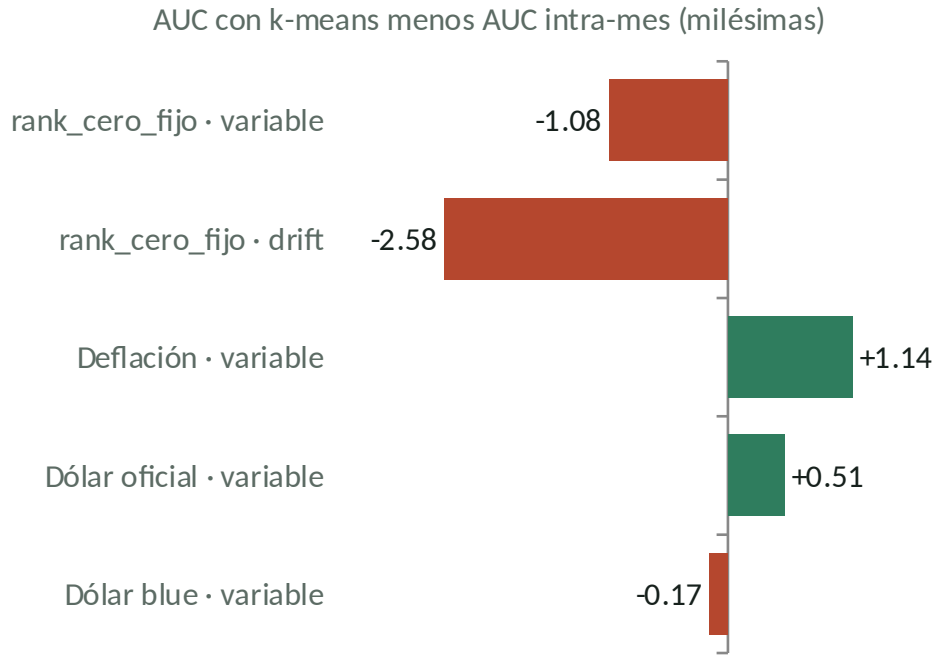
Como drift: rank dentro del cluster, 272 campos.

K-means suma 10 campos (282) y, con rank_cero_fijo, no mejora a la configuración 01.

Ranking de las 9 combinaciones



¿Sirve el k-means?



Comparación	Mejoran	p
rank_cero_fijo · variable	1/10	**0.0080**
rank_cero_fijo · drift	0/10	**0.0059**
Deflación · variable	9/10	**0.0108**
Dólar oficial · variable	5/10	0.2213
Dólar blue · variable	5/10	1.0000

Mejoran: semillas (de 10) donde k-means supera a intra-mes. Wilcoxon pareado por semilla.

Wilcoxon contra la mejor

9–10 de 10

semillas en que la 01 gana a cada una de las otras 8

0.0015–0.021

p no pareado con corrección de Holm

0.0011–0.0028

diferencia de AUC medio a favor de la 01

Cómo se lee

Prueba principal: no pareada, porque cada configuración tiene otros campos e hiperparámetros. Holm corrige las 8 comparaciones.

El rival más cercano

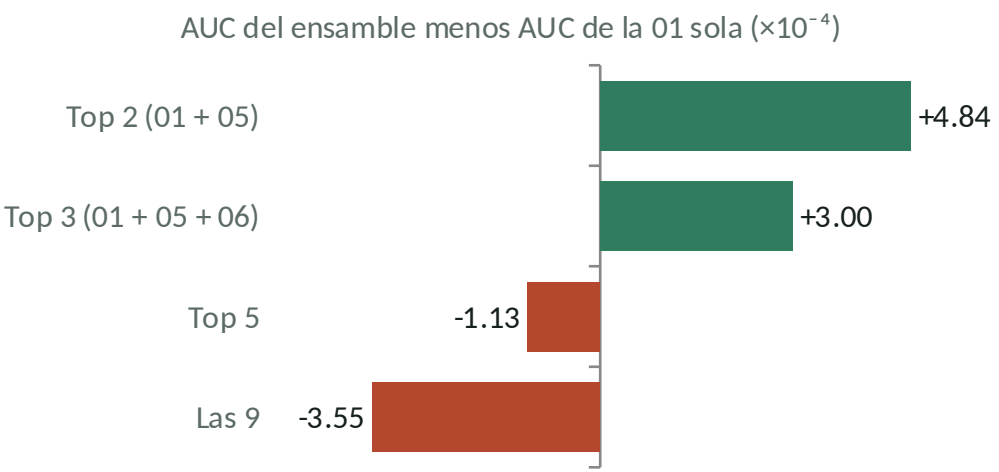
La 05 (p Holm = 0.021). En la prueba pareada el piso es p = 0.0474 con 10 semillas y 8 comparaciones.

Hiperparámetros ganadores

Configuración	Hojas	min_data	feat. frac.	Iter.	Min.	AUC grid
01 · rank_cero_fijo · intra-mes	**256**	**2048**	**0.8**	**140**	**48.8**	**0.9361**
05 · rank_cero_fijo · k-means variable	512	512	0.5	103	51.7	0.9357
06 · deflación · k-means variable	512	1024	0.5	96	48.9	0.9345
04 · dólar blue · intra-mes	384	2048	0.8	100	47.9	0.9340
08 · dólar blue · k-means variable	256	1024	0.5	102	54.4	0.9341
07 · dólar oficial · k-means variable	384	1024	0.8	111	50.0	0.9339
09 · rank_cero_fijo · k-means drift	128	2048	0.5	190	64.0	0.9337
02 · deflación · intra-mes	128	512	0.8	103	45.2	0.9336
03 · dólar oficial · intra-mes	256	2048	0.8	85	45.3	0.9342

Las 4 intra-mes eligieron feature_fraction 0.8; 4 de las 5 con k-means eligieron 0.5.

Ensambles entre combinaciones



Combinación	AUC
La mejor sola (01)	0.935758
Top 2 (01 + 05)	**0.936242**
Top 3 (01 + 05 + 06)	0.936058
Top 5	0.935645
Las 9	0.935403

Sumar pocas combinaciones buenas y distintas ayuda (+0.0005); sumar también las peores diluye la señal. Se promedian los ranks de las probabilidades de validación.

La mejor combinación

Corrección	rank_cero_fijo
Variables	Intra-mes + lag1, lag2, delta1 y delta2 (272 campos)
K-means	No
LightGBM	256 hojas · min_data_in_leaf 2048 · feature_fraction 0.8
Entrenamiento	10 semillas; se promedian las probabilidades

AUC 0.9349 ± 0.0006

Ensamble de las 10 semillas: 0.9358

Para ensamblar

05: rank_cero_fijo con k-means como variable. El ensamble 01 + 05 llega a AUC 0.93624.

Mejor evitar

Dólar oficial o IPC sin k-means (03, 02) y k-means como drift (09): los tres últimos.

Lo que sigue: NEW202

11 · lag3 y lag6

Por correr

Suma lag3, lag6 y sus deltas a la configuración 01.

484 campos

12 · medias móviles

Por correr

Suma medias móviles de 3 y 6 meses y sus diferencias.

484 campos

13 · grid ampliado

Por correr

Mismas variables que la 01, con 75 combinaciones en vez de 50.

272 campos

14 · todo junto

Por correr

Lags largos, medias móviles y grid ampliado a la vez.

696 campos

Cada cambio: 10 semillas contra la 01. Mejora si p Holm < 0.05 y la diferencia es positiva.

Qué tan firme es el resultado

1 Un solo mes de validación

202107 es el único disponible; elegir y evaluar en el mismo mes es optimista.

2 AUC no es ganancia

La ganancia depende del ranking en la cima; el AUC, del ranking completo.

3 Wilcoxon con 10 semillas

El pareado tiene piso p = 0.0474; por eso el no pareado es la prueba principal.

4 Sin envío a Kaggle

Los archivos con cortes 1600–2600 están generados pero no se subieron.

Cómo reproducirlo

1. **NEW201_drift_10semillas.ipynb**

   Corre las 9 configuraciones y guarda todo en exp/NEW201

2. **NEW201_wilcoxon_y_ensambles.R**

   Wilcoxon contra la mejor y ensambles entre configuraciones

3. **NEW201_presentacion_final.ipynb**

   Tablas y gráficos de los resultados

4. **NEW202_mejoras_sobre_la_01.ipynb**

   Mejoras; usar carpeta nueva (NEW203) y prueba_rapida = FALSE